Data Lake și U-SQL

Conf.dr. Cristian KEVORCHIAN

Universitatea din București

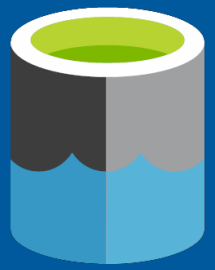

Data Lake – Generalități

Azure Data Lake – Definiție

Un singur punct de stocare a datelor , în care plecând de la date brute (care provin printr-o preluare exactă dintr-o sursă dată) care prin extragere, analiză și organizare a unor volume mari de date rezultă analize profunde într-o formă acceptabilă, utilă și benefică pentru o anumită utilitate data(social, economică, științifică etc.

Livrate de o manieră open source

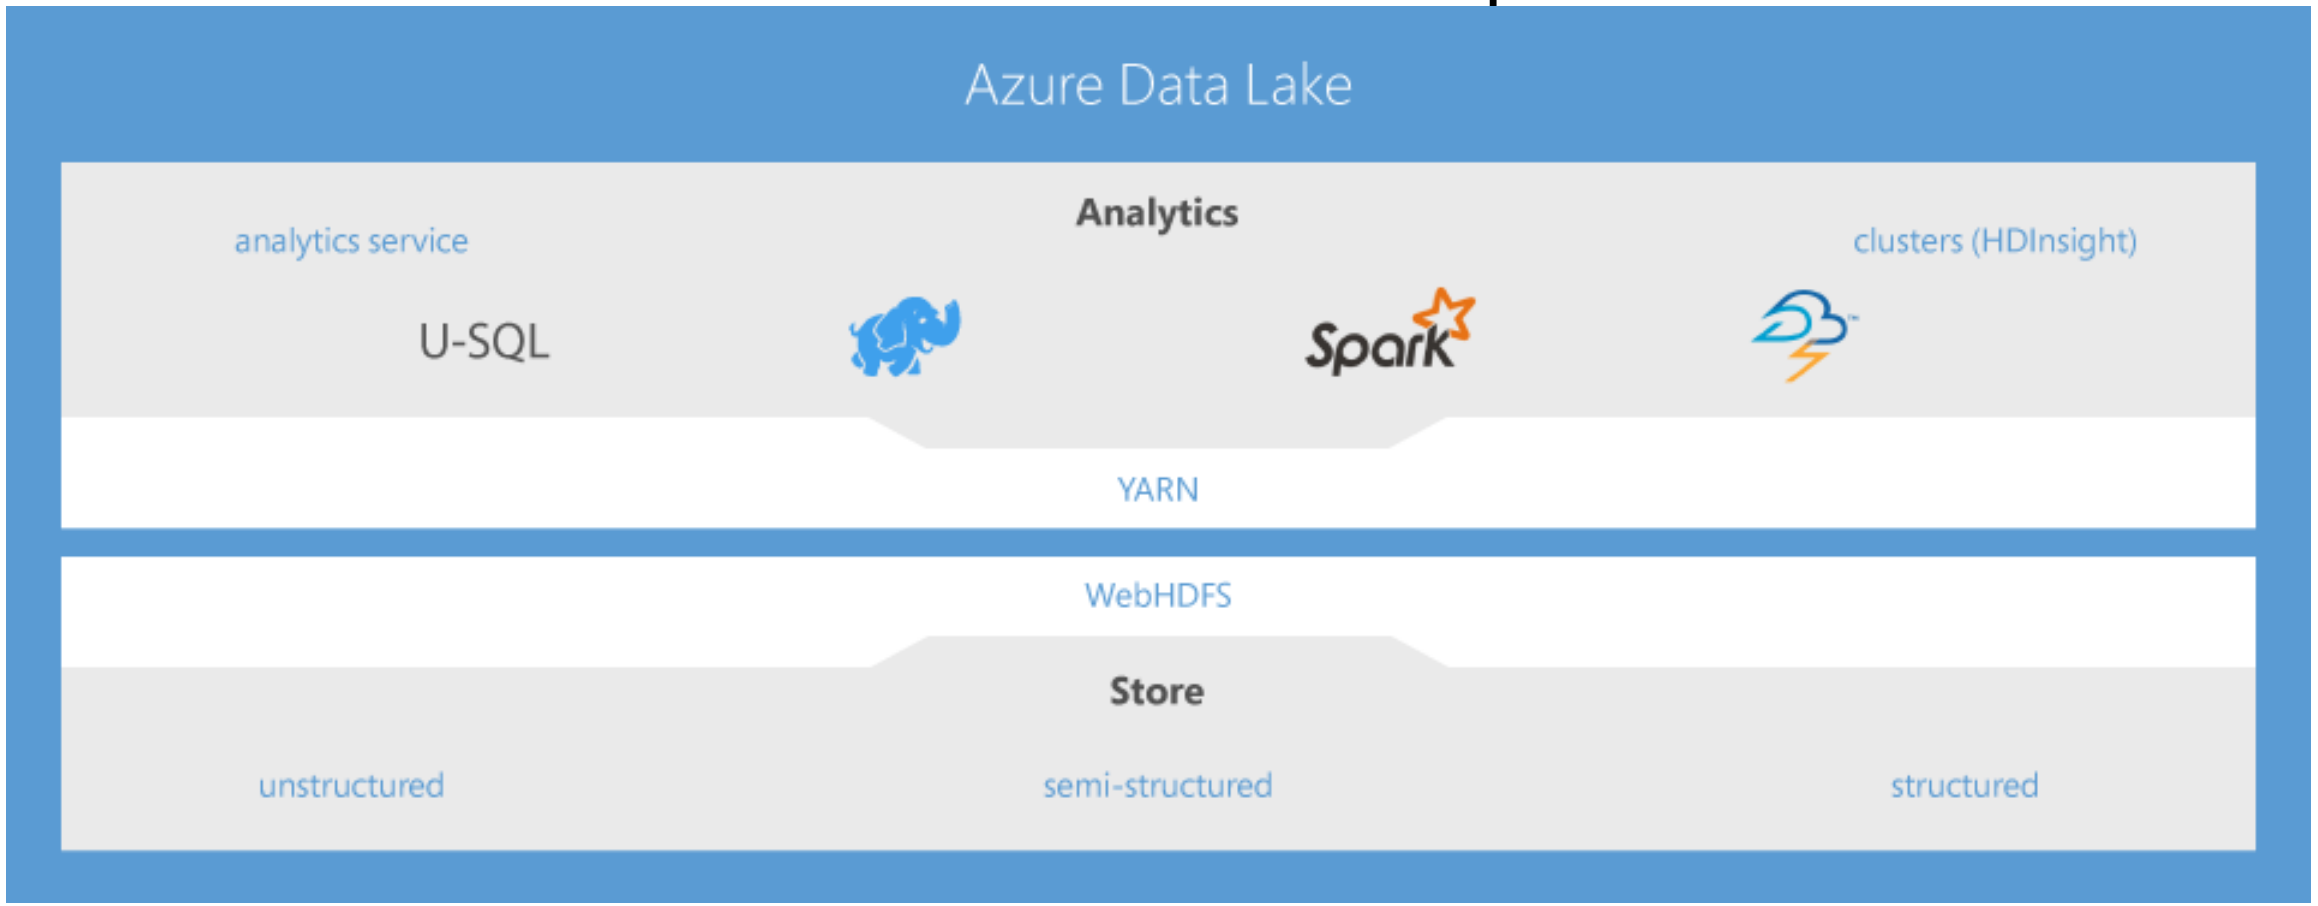

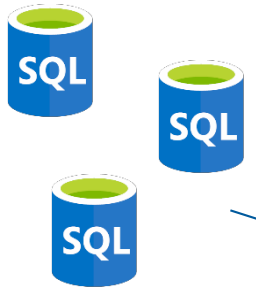

Federalizarea surselor de date SQL

Vizualizare

Data Discovery

Import Date

Securitate

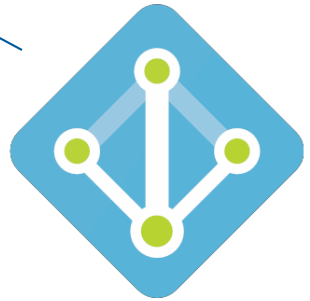

Azure Data Lake

Funcționalități oferite de Data Lake

- Analitice (Data Lake Analytics)
- Hadoop Cluster as a Service(HDInsight)
- Stocare(Data Lake Store)
- Dezvoltare, debuging și optimizare de aplicații Big Data
- Stocare și analiză collecții de date de dimensiuni mari (petabyte) și trilioane de entități
- Securitate, audit și asistență la nivel de ”enterprise”

Data Lakes vs Data Warehouses

DATA WAREHOUSE	vs.	DATA LAKE
Procesare eminamente structurată	DATA	Structurat, SemiStructurat, NeStructurat, Brut
Schema-on-Write	PROCESARE	Schema-on-Read
Costuri mari pentru volume mari de date	STORAGE	Proiectate pentru democratizarea costurilor de stocare
Agilitate scăzută Configurare fixă	AGILITATE	Agilitate ridicată Configurarea și reconfigurarea un ”must”
Matură	SECURITATE	Matură
Specialisti BI	UTILIZATORI	Specialisti în Data Scientist

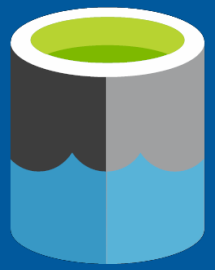

Data Lake Store

Data Lake Store – Definiție

- Un repository fault-tolerant și distribuit global de nivel inalt destinat furnizării de analitice big data de mare complexitate.
  - O structură Data Lake permite captarea și stocarea de date fără o limită de volum(deocamdată), tip, și viteză de ingestie intr-un singur punct în scopul furnizării de analitice operaționale și exploratorii.

- Poate fi accesat din Hadoop (disponibil prin cluster-ul HDInsight) utilizand WebHDFS-compatibil REST.

- Conceput special pentru a permite dezvoltarea de analitice peste datele stocate fiind optimizat pentru implementarea de scenarii de analiză complex a datelor.

- Include ”out of the box”, toate standardele de nivel enterprise
  - securitate, management intuitiv, scalabilitate, încredere, și disponibilitate

DATA LAKE STORE	vs.	BLOB STORAGE
Stocare Optimizată pentru sarcini de dezvoltare de analitice big data	**SCOP**	Stocare de nivel general pentru o varietate largă de scenarii de stocare
Batch, interactiv, analitice în timp-real și date destinate ML cum ar fi fisiere log, date in IoT, stream-uri de click-uri, seturi de date de volume mari	**UTILIZARE**	Orice tip de date text sau binare livrate deback-end, backup-uri, stocari media pentru streaming si date de interes general
Un cont de Data Lake Store este organizat pe foldere care contin fisiere de date stocate.	**CONCEPTE**	Un cont de Storage contine containere, care contin date ca blob-uri
Sistem de fisiere ierahic constituite	**STRUCTURĂ**	Obiecte stocate și identificate prin namespace
Bazat pe managementul identității furnizat de Azure Active Directory	**SECURITATE**	Bazat pe - Account Access Keys și Shared Access Signature Keys.

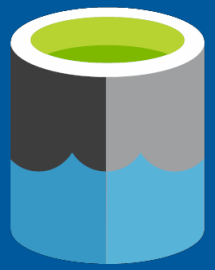

Analitice Data Lake

Analitice Data Lake – Definiție

- Conceput special pentru a permite analiza datelor stocate fiind optimizat pentru dezvoltarea de scenario complexe de analiză a datelor.
- Realizează cu prioritate scrierea, rularea și gestionarea job-urilor, lăsând pe planul doi operarea infrastructurii distribuite.
- Poate gestiona execuția de job-uri la orice scară, dimensionând resursele necesare.
- Se plateste pentru acel job care se execute., fiind cost-effective.
- Serviciul de analiză acceptă Azure Active Directory, fapt ce permite gestionarea accesului și rolurilor, integrate cu sistemul de identitate local.

Analitice Data Lake – Functionalități cheie

- Scalare dinamică
- Dezvoltare rapida, debugging și optimizare prin utilizarea unor familii de instrumente familiar.
- U-SQL: simplu și extensibil
- Integrare larga de componente IT ce operează cu date din Azure.

HDInsight

Azure HDInsight

- O solutie cloud full-maged pentru Apache Hadoop
- Furnizează analitice open-source loptimizate la nivelul clusterului pentru
  - Spark,
  - Hive,
  - MapReduce,
  - HBase,
  - Storm,
  - Kafka,
  - Microsoft R Server
- Un SLA 99.9%
- Instalarea acestei tehnologii Big data și a aplicatiilor ISV(independent Software Vendor) in comtextul ”managed cluster” cu Securitate livrată la nivel enterprise.

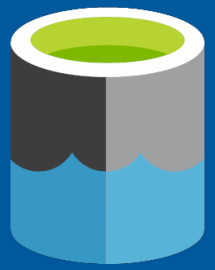

U-SQL

U-SQL

Este un limbaj de interogare destinate soluțiilor Big Data(serviciile Data Lake Analytics)

A evoluat ca proiect intern al Microsoft

SCOPE : Simplu și Eficient

Masiv Paralel destinate volumelor

mari de date

de Ronnie Chaiken, Bob Jenkins, Per-Åke Larson, Bill Ramsey,

Darren Shakib, Simon Weaver, Jingren Zhou

http://www.vldb.org/pvldb/vol1/1454166.pdf

U-SQL combină

- limbaj declarativ
- Tipuri si expresii C#
- Asemanari cu Hive si LINQ
- Concepte de procesare Big Data cum ar fi “schema on reads”,

Interogheaza si cmbină date dintr-o varietate de surse

- Azure Data Lake Storage,
- Azure Blob Storage,
- Azure SQL DB, Azure SQL Data Warehouse,
- Instante SQL Server executate pe masini virtuale.

Nu este ANSI SQL

- SELECT trebuie scris cu majuscule
- Expresiile din cadrul clauzei SELECT predicatele WHERE etc sunt C#.
- Asta inseamna că operatorii de comparare sunt sintactic cei din C# (a == "foo"),
- Utilizează semantica null din C# care este una cu 2-valori si nu una cu 3-valori ca în ANSI SQL.

Procesarea script-urilor U-SQL

- Azure Data Lake Analytics utilizează U-SQL pentru procesare batch.
- U-SQL este scris și executat în format de script batch.
- U-SQL suportă definire de date cu CREATE TABLE, artefacte destinate lucrului cu metadate fie în scripturi separate, fie chiar în combinație cu scripturile de transformare.
- U-SQL permite execuția scripturilor dupa cum urmează:
  - Direct din Azure Data Lake Tools pentru Visual Studio,
  - Din portalul Azure
  - Programat via Azure Data Lake SDK. API-ul de execuție al job-urilor.
  - Azure Powershell extensia dedicată comenzilor destinate ”job submission”

Scipt-uri U-SQL și procesarea datelor

Se aplică următorul pattern de procesare:

- Preluarea datelor din locațiile stocate drept familii de linii
  - Locațiile de stocare pot fi fisiere care vor fi ”schematizate” ”on read” cu EXTRACT
  - Locatiile de stocare pot fi tabele U-SQL care sunt incarcate intr-un format ”schematizat”
  - Locatiile de stocare pot fi tabele furnizate din alte surse cum ar fi baze de date Azure SQL
- Transformarea familiilor de linii
  - Mai multe transformări peste seturile de linii pot fi tratate într-un format de flux de date
- Stocarea datelor care au fost supuse transformării
  - Incarcarea intr-un fisier cu aluza OUTPUT, sau
  - Incarcarea într-o tabelă U-SQL cu ajutorul clauzei INSERT

Script U-SQL

```
DECLARE @in  string = "/Samples/Data/SearchLog.tsv";
DECLARE @out string = "/output/result.tsv";

@searchlog =  EXTRACT UserId int, Start DateTime, Region string, Query string,
                      Duration int?, Urls string, ClickedUrls string
               FROM @in  USING Extractors.Tsv();

@rs1 = SELECT Start, Region, Duration FROM @searchlog WHERE Region == "en-gb";

@rs1 = SELECT Start, Region, Duration FROM @rs1
       WHERE Start >= DateTime.Parse("2012/02/16");

OUTPUT @rs1
TO @out
USING Outputters.Tsv();
```

DEMO

- Creare Data Lake Store
- Creare cont Data Lake Analytics și conectare cu Data Lake Stores
- Import date în Data Lake Stores
- Execuție job-uri U-SQL în Azure Data Lake Analytics